

AI GPU 方向组会进展

从 GPU Trace Compression 收敛到 AI Decode 下的 Warp Scheduling 分析

dyf

2026-04-05

背景与问题重定义

当前研究问题已经收敛，不再是“单纯做 trace 压缩”。

主线变成：

difftest 风格的压缩与验证

-> 保留 warp-level 行为语义的 GPU trace 表示

-> AI workload 中 warp scheduling 失效模式分析

为什么这样收敛：

- 只讲压缩率，体系结构贡献不够硬
- 只做工具链，容易停留在工程优化
- 果 trace 表示能保留控制结构、重复结构和跨层差分，就有机会支撑后续调度分析与优化

研究主线与当前定位

为什么把主问题转到 warp scheduling:

- dense matmul / GEMM 通常更规则，调度效应容易被算力吞吐掩盖
- LLM inference, 尤其是 decode 阶段的 attention + KV-cache, 更容易暴露:
 - warp 间推进不均衡
 - memory stall 长尾
 - ready warp 与高收益 warp 不一致
- 当前压缩结构已有信息天然接近调度语义:
 - shared PC sequence
 - warp diff
 - address delta / override

当前采用的压缩手段

当前不是单一压缩算法，而是一套分层编码策略：

类别	当前采用的手段
Delta encoding	PC delta; threadblock 间 base + offset + override
Default elision	active mask 全活跃时省略; predicate 与 active 相等时省略
Run-length / sequence compression	instruction run; sequence + run 结构展开恢复
Cross-entity deduplication	跨 warp 共享 PC skeleton; 跨 threadblock 共享 base, 只保留 override

可以这样理解：

当前已完成工作与测试结果

压缩与恢复链路

- 已实现 $v4 \leftrightarrow v5 / v6 / v7 / v8$ 的核心编码与解码
- `test_roundtrip` 当前结果: **9 passed, 0 failed**

当前已能明确给出的压缩比

- `v4 -> v5` 合成 threadblock 单元测试:
 - 原始大小: 258 B
 - 压缩后大小: 132 B
 - 压缩后为原始大小的 **51.16%**
 - 等价压缩倍数约 **1.95x**

当前限制

AI Trace 方向的最小实验闭环

当前已经决定的 AI workload 路线：

- 不先做 training，先做 inference
- 不先做 full forward，先做 decode
- 不先做大模型，先用 GPT-2 small 打通链路
- 主研究对象先放在 attention + KV-cache
- matmul / GEMM 保留为后续对照组

已经新增的实验脚手架：

- `experiments/gpt2_decode/run_decode.py`
- `experiments/gpt2_decode/run_trace.sh`
- `experiments/gpt2_decode/summarize_runs.py`

为什么 Squash / Batch 适合和 AI 读 Trace 结合

目标：让 AI 能从 trace 中定位问题，而不是只做离线存储压缩。

Squash:

- 把重复执行段、等价局部行为压成“逻辑片段”
- 相当于把 raw trace 切成 AI 可读的 semantic chunks

Batch:

- 把细粒度事件提升到 warp / threadblock / kernel 粒度组织
- 相当于给 AI 提供可逐层下钻的 hierarchical context

定位链可以设计成：

```
Kernel summary -> Threadblock summary -> Warp episode -> 可疑长尾 / stall  
/ divergence 片段
```

4 个月投稿窗口下的阶段计划

阶段 1：打通链路并验证可行性

- 完成 GPT-2 decode trace 生成
- 跑通汇总分析
- 确认 trace 中存在可稳定观测的 warp-level 结构变化

阶段 2：形成解释型结果

- 从 attention / KV-cache trace 中提取 warp scheduling 相关特征
- 与 matmul 做对照
- 找出一个稳定、可解释的 scheduler 失效模式

阶段 3：寻找设计机会

- 不强行做大机制

当前风险与总结

当前风险：

- decode ROI 中 attention kernel 可能还不够干净
- GPT-2 small 可能过于简单，不足以暴露真实 scheduler 失效模式
- 真实 workload 上 v5-v8 的压缩比与等价性验证还未补齐
- 果只有解释型结果，没有设计点，体系结构投稿力度可能不足

一句话总结：

我们正在把“GPU trace 压缩”收敛为一套借鉴 difftest 思想、可保留 warp-level 行为语义的层次化 trace 表示，并尝试用它分析 LLM decode 中 attention / KV-cache 引发的 warp scheduling 失效模式，进一步寻找体系结构上的调度优化机会。